

Akademija velikih jezikovnih modelov

GZS, 2025



Kdo sva?



Luka Vranješ
luka@valira.ai



Andrej Miščič
andrej@valira.ai



rešitve po meri na področju AI,
strojnega učenja in širše
podatkovne znanosti



AI layer unifying enterprise
knowledge — from documents
and ERP to 3D models and
drawings

Agenda

1. Predavanje:
 - a. RAG
 - b. LLM agenti (ReAct)
2. Gradnja agentov z Google ADK
3. Trendi v svetu LLM-jev:
 - a. MCP
 - b. A2A
 - c. AG-UI

01

RAG


retrieval-augmented generation

RAG (Retrieval-augmented generation)

(“odgovarjanje na vprašanja s pridobivanjem informacij”)

RAG (Retrieval-augmented generation)

(“odgovarjanje na vprašanja s pridobivanjem informacij”)




Vaša zbirka dokumentov

1000s, 100k, 1M+

Vektorska baza
(vector DB)

RAG (Retrieval-augmented generation)

(“odgovarjanje na vprašanja s pridobivanjem informacij”)



RAG - motivacija

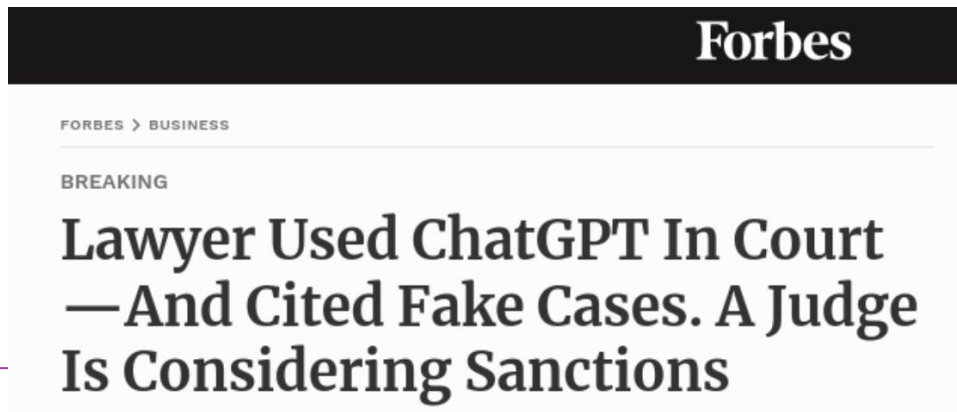
- znanje LLM-jev je omejeno na statične učne podatke
- če želimo v LLM-je vpeljati novo znanje, jih lahko povežemo z zunanjimi bazami znanja:
 - analogija: ljudje poiščemo informacije na spletu, Wikipediji, knjigah

RAG - priložnost

- povezava LLM-jev z internim znanjem organizacij:
 - ni dostopno med učenjem LLM-jev, zato ni prisotno v odgovorih
 - bazo znanja sestavljajo interni dokumenti organizacije
- zmanjšanje tveganja halucinacij, saj odgovori črpajo iz preverjenih virov
- citati - LLM-ji lahko pri odgovorih citirajo vire informacij, ki jih uporabniki lahko preverijo


RAG - priložnost

- povezava LLM-jev z internim znanjem organizacij:
 - ni dostopno med učenjem LLM-jev, zato ni prisotno v odgovorih
 - bazo znanja sestavljajo interni dokumenti organizacije
- zmanjšanje tveganja halucinacij, saj odgovori črpajo iz preverjenih virov
- citati - LLM-ji lahko pri odgovorih citirajo vire informacij, ki jih uporabniki lahko preverijo



Sestavimo RAG

1. **Baza znanja**
2. Iskanje informacij
3. Tvorjenje odgovora




Baza znanja (*knowledge base*)

= urejena zbirka besedil, ki nam omogoča iskanje informacij

Baza znanja (*knowledge base*)

= urejena zbirka besedil, ki nam omogoča iskanje informacij



Baza znanja

- **zbirka dokumentov**
- deljenje (*chunking*)
- vložitve (*embeddings*)
- vektorska baza (*vector DB*)

Predstavlja znanje, ki ga bomo
“vnesli” v LLM:

- **interno znanje:** privatni dokumenti
- **domensko znanje:** besedila iz nišnih domen

Baza znanja

- zbirka dokumentov
- **deljenje (*chunking*)**
- vložitve (*embeddings*)
- vektorska baza (*vector DB*)

Dolga besedila razdelimo na krajše enote, npr. 50 strani dolga navodila razdelimo po poglavjih.

Baza znanja

- zbirka dokumentov
- **deljenje (*chunking*)**
- vložitve (*embeddings*)
- vektorska baza (*vector DB*)

Dolga besedila razdelimo na krajše enote, npr. 50 strani dolga navodila razdelimo po poglavjih.

- + hitrejše procesiranje
- + razšumljanje (znebimo se irelevantnih informacij)
- + cenovno ugodneje

Baza znanja

- zbirka dokumentov
- **deljenje (*chunking*)**
- vložitve (*embeddings*)
- vektorska baza (*vector DB*)

Dolga besedila razdelimo na krajše enote, npr. 50 strani dolga navodila razdelimo po poglavjih.

- več dokumentov
- informacije morda razdeljene med več dokumentov

Baza znanja

- zbirka dokumentov
- deljenje (*chunking*)
- **vložitve** (*embeddings*)
- vektorska baza (*vector DB*)

Vsak dokument predstavimo z vektorsko vložitvijo (*embedding*).

- z modeli kot je BERT
- vložitev je numerična predstavitev besedila, ki omogoča, da matematično obravnamo razmerja med besedili

Baza znanja


- zbirka dokumentov
- deljenje (*chunking*)
- vložitve (*embeddings*)
- **vektorska baza (*vector DB*)**

Omogoča učinkovito iskanje po dokumentih.




Baza znanja

- zbirka dokumentov
- deljenje (*chunking*)
- vložitve (*embeddings*)
- vektorska baza (*vector DB*)



Sestavimo RAG

1. Baza znanja
2. **Iskanje informacij**
3. Tvorjenje odgovora



Iskanje

= pridobivanje dokumentov, ki so *relevantni* za uporabnikovo vprašanje.




imajo *podobno* vektorsko vložitev (predstavitev)




podobno glede na kosinusno podobnost

Kosinusna podobnost




Iskanje

- skrčimo število dokumentov na le nekaj relevantnih (e.g. 5 do 10)



Sestavimo RAG

1. Baza znanja
2. Iskanje informacij
3. **Tvorjenje odgovora**



Tvorjenje odgovora

Prompt:

- vsebuje uporabnikovo vprašanje
- vsebuje relevantne dokumente
- poziva, da naj odgovor črpa iz danih dokumentov

Tvorjenje odgovora

Glede na dane dokumente odgovori na spodnje vprašanje. Če ni možno odgovoriti z danimi informacijami, to napiši, namesto da odgovoriš sam.

Dokumenti:

{dokument 1}


{dokument 2}

{dokument 3}

Vprašanje:

?

Povežimo vse skupaj



offline del:

- priprava baze znanja

online del:

- iskanje dokumentov
in tvorjenje odgovora

02

LLM agenti (ReAct)



RAG

- primeren za statične, nestrukturirane podatke:
 - zgradimo bazo znanja in jo posodobimo po potrebi

RAG

- primeren za statične, nestrukturirane podatke:
 - zgradimo bazo znanja in jo posodobimo po potrebi
- dinamični podatki/podatki v realnem času:
 - npr. trenutno vreme, trenutno stanje v prometu, trenutni podatki v bazi, itd.
 - bolje bi bilo, če bi LLM lahko dostopali do takšnih podatkov prek aplikacijskih programskih vmesnikov (API-jev).

LLM agenti

= LLM-ji, ki lahko komunicirajo z zunanjim svetom z izvajanjem *orodji*

Orodje (*tool*):

- funkcija, ki jo lahko pokliče LLM z nekimi vhodnimi parametri
- lahko si predstavljamo API klic

Orodje (*tool*/) - primeri

1. komunikacija s podatkovnimi bazami:
 - vhod: SQL poizvedba
 - izhod: rezultat SQL poizvedbe

Orodje (*tool*) - primeri

1. komunikacija s podatkovnimi bazami
2. pridobivanje dinamičnih podatkov v realnem času, npr.:
 - pridobivanje podatkov o vremenu prek ARSO API-ja
 - pridobivanje podatkov o prometu prek DARS API-ja
 - ...

Orodje (*tool*) - primeri

1. komunikacija s podatkovnimi bazami
2. pridobivanje dinamičnih podatkov v realnem času
3. izvajanje akcij, npr.:
 - potrditev nakupa izdelka
 - rezervacija mize v restavraciji
 - ...

Orodje (*tool*) - primeri


1. komunikacija s podatkovnimi bazami
2. pridobivanje dinamičnih podatkov v realnem času
3. izvajanje akcij
4. ...

ReAct cikel

- pristop za razvoj agentov: Reason + Act = ReAct

ReAct cikel

- pristop za razvoj agentov: Reason + Act = ReAct
- **Reason:** razmišljanje pomaga LLM agentu izbrati pravilno orodje
- **Act:** ravnanje - uporaba orodja



ReAct (Reason + Act)

ReAct cikel

- ReAct cikel je zaporedje:
 - misel: katero orodje uporabiti, s kakšnim vhodom
 - izvedba orodja
 - branje izhoda iz orodja

ReAct psevdokoda

```
function react_answer (question):  
    history = [question]  
  
    for i in range(MAX_ITERATIONS):  
        thought = llm(history)  
        history.add(thought)  
  
        action = llm(history)  
  
        tool, tool_input = parse_action(action)  
  
        if tool == "answer":  
            return tool_input  
  
        observation = tool(tool_input)  
        history.add(action, observation)  
  
    raise Error("Max iteration exceeded")
```

Primer izvajanja LLM agenta

Uporabnik: Kakšno je vreme v Kopru?

Agent:

interno

- *misel*: Uporabiti moram ARSO orodje za pridobitev podatkov o vremenu.
- *orodje*: **ARSO**, vhod: {"lokacija": "Koper"}
- *izhod orodja*: {"lokacija": "Koper", "temp.": "22", "stanje": "jasno"}
- *misel*: Imam dovolj informacij za odgovor.
- *orodje*: **odgovor**, "Toplo in jasno"


Agent: Toplo in jasno.

02




Standardizacija komunikacije v svetu LLM agentov

The Agent Protocol Stack



MCP: model context protocol

- protokol, ki standardizira, kako se LLM-ji povezujejo z zunanjimi sistemi
- zunanji sistemi:
 - orodja
 - viri podatkov, prompti
 - interakcija z uporabnikom
 - ...



MCP: model context protocol

- odstrani potrebo po prevajanju med različnimi implementacijami

Posledica:

- vaš LLM agent se lahko poveže na zunanja orodja, ki podpirajo MCP standard
- vaša organizacija lahko servira orodja prek MCP standarda, na katere se lahko povezujejo zunanji sistemi/agenti

MCP arhitektura

